

CATEGORIA CONCLUÍDO

1. RESUMO

Algoritmos de aprendizado supervisionado são tradicionalmente descritos por procedimentos de otimização específicos de cada modelo. Essa perspectiva dificulta a identificação de uma estrutura comum que permita combinar modelos de maneira sistemática. Este trabalho investiga uma abordagem categorial para o aprendizado supervisionado, na qual modelos são representados como morfismos da categoria *Learn* e sua composição determina tanto a predição quanto a propagação do aprendizado. A partir da construção de *Backprop as a Functor: A compositional perspective on supervised learning* (2019), implementou-se em Haskell uma representação tipada de learners, utilizando listas heterogêneas de parâmetros para representar o espaço parametrizado das composições. Além da composição sequencial, foi implementada uma operação de composição paralela que permite executar dois learners independentemente sobre componentes distintos de uma entrada e combinar seus resultados em uma única estrutura. A abordagem foi avaliada em modelos de regressão linear simples, regressão com padronização e regressão polinomial. Os resultados mostram que a composição permite acrescentar transformações de dados e não-linearidades sem modificar a estrutura interna dos modelos de aprendizado, enquanto a composição paralela estende essa capacidade para arquiteturas com fluxos independentes de processamento. Os experimentos indicam que a perspectiva categorial fornece uma abstração adequada para descrever a construção estrutural de modelos compostos e para compreender a retropropagação como consequência da própria composição.

2. INTRODUÇÃO

O aprendizado supervisionado é normalmente apresentado como um conjunto de algoritmos que recebem dados de entrada, produzem previsões, calculam uma função de erro e atualizam seus parâmetros por algum procedimento de otimização. Embora essa descrição seja adequada para a implementação, ela privilegia o aspecto procedural do aprendizado e não explicita a estrutura que permite combinar diferentes modelos (Goodfellow *et al.*, 2016).

Essa questão torna-se relevante quando diferentes transformações podem ser encadeadas para produzir um modelo mais complexo. Uma transformação pode realizar uma mudança de representação dos dados, enquanto outra executa a previsão e uma terceira introduz uma nova característica. Em uma descrição puramente procedural, essas operações podem aparecer como etapas independentes de um programa. Sob uma perspectiva estrutural, entretanto, elas podem ser interpretadas como morfismos que admitem composição.

Fong *et al.* (2019) formalizam essa perspectiva por meio da categoria Learn, na qual um algoritmo de aprendizado, denominado learner, é representado por um conjunto de parâmetros, uma função de implementação, uma função de atualização e uma função de requisição. A composição desses componentes reproduz o mecanismo de retropropagação (backpropagation), fazendo com que a propagação do erro entre modelos seja consequência da estrutura categorial.

Este trabalho implementa essa abordagem em Haskell e investiga sua aplicação na construção de modelos de regressão. A implementação utiliza listas heterogêneas de parâmetros indexadas por tipos, substituindo a representação direta por produtos cartesianos. Além da composição sequencial apresentada por Fong *et al.* (2019), é introduzida uma composição paralela capaz de combinar dois learners que operam independentemente sobre componentes de uma entrada.

3. OBJETIVOS

O objetivo principal deste trabalho é analisar em que medida a representação categorial permite construir modelos progressivamente mais expressivos sem modificar a estrutura fundamental dos componentes.

Como objetivos específicos: 1) Avaliar três modelos de regressão sob esta ótica; 2) Implementar e analisar a operação paralela como mecanismo para a construção de arquiteturas com fluxos independentes de processamento.

4. METODOLOGIA

A metodologia computacional adotada baseia-se na implementação tipada dos parâmetros. Na formulação matemática, a composição de dois learners com espaços de parâmetros P e Q produz $P \times Q$. Em Haskell, uma representação direta por tuplas apresenta uma limitação prática de associação sintática. Para reduzir essa dependência, a implementação representa os parâmetros por listas heterogêneas indexadas por uma lista de tipos. A composição concatena as listas de tipos, permitindo que a estrutura dos parâmetros acompanhe a estrutura da composição.

A estrutura de cada learner implementado contém funções correspondentes à predição (l), atualização (U) e requisição (r), além de um estado inicial de parâmetros. A composição sequencial divide o espaço de parâmetros composto entre os dois componentes, executa a predição de forma encadeada e realiza as atualizações de acordo com a regra de aprendizado. A composição paralela utiliza a mesma representação de parâmetros, onde dado um par de learners, seus parâmetros são concatenados, enquanto a entrada e a saída são representadas por pares. A atualização e a requisição ocorrem independentemente em cada ramo.

No protocolo experimental, foram construídos três modelos de regressão: regressão linear simples, regressão com padronização prévia ao regressor, e regressão polinomial (adicionando uma transformação quadrática e padronização). Em todos os modelos foi utilizada a função de erro quadrático e a atualização dos parâmetros por descida do gradiente. Os experimentos utilizaram dados sintéticos com ruído e avaliaram a proximidade entre os parâmetros aprendidos e os coeficientes das funções geradoras originais.

5. DESENVOLVIMENTO

O referencial base é a categoria Learn. Na formulação de Fong *et al.* (2019), os objetos da categoria Learn são conjuntos e um morfismo de A para B é um learner constituído por um espaço de parâmetros e as três funções supracitadas. A função l representa o comportamento observável do modelo, a função U descreve como os parâmetros são modificados diante de um treinamento e r determina qual informação deve ser encaminhada ao componente anterior. A identidade fornece o elemento neutro para a composição sequencial.

Para a composição sequencial de dois learners, f e g , a composição $g \circ f$ possui espaço de parâmetros combinado, e a implementação é obtida pela execução sequencial. O erro recebido por g é utilizado para produzir a informação necessária para f . A retropropagação não precisa ser um procedimento externo: a informação para atualização emerge da própria composição.

A composição paralela descreve uma estrutura diferente. Para ampliar a expressividade estrutural, foi implementada uma operação paralela ($//$). A implementação opera cada componente de forma independente, sendo a atualização também independente em cada ramo. A requisição é calculada separadamente e, posteriormente, recombina. Isso estende a representação estrutural de pipelines sequenciais para fluxos ramificados independentes, fundamentais em arquiteturas de aprendizado mais sofisticadas.

6. RESULTADOS

Regressão linear simples: O primeiro modelo apresentou convergência aproximada para os parâmetros da função geradora $(2x+1)$. Observou-se, no entanto, forte dependência da taxa de aprendizado, sendo o comportamento compatível com a diferença de escala entre os gradientes do coeficiente angular e do intercepto. A limitação não ocorreu pela composição, mas pelas propriedades de otimização numérica, o que forneceu o motivador para a inclusão da padronização.

Regressão com padronização: O segundo modelo compôs a regressão linear com um learner de padronização (transformação $(x-\mu)/\sigma$). A estrutura tornou-se

'regressorLinear o padronizador'. A requisição do padronizador propagou o gradiente, mitigando a sensibilidade à escala sem necessidade de alterar o regressor internamente. A melhoria de performance e redução da anisotropia resultou estritamente da adição estrutural.

Regressão polinomial: Investigou-se a não-linearidade através de um learner quadrático antes das demais estruturas (regressorLinear o padronizador o quadrático). Obteve-se aproximação aos coeficientes originais da base ($0,3x^2-3$). A expressividade do modelo foi ampliada sem refazer o modelo linear, provando o ganho da abordagem morfológica categorial.

Em relação à composição paralela e extensão estrutural, foi provado que o modelo categorial permite que dois learners processem componentes distintos e independentes da entrada. O erro associado a cada saída foi roteado com sucesso ao seu componente, sem mistura de gradientes, servindo de base teórica para aplicações em redes com fluxos separados.

7. CONSIDERAÇÕES FINAIS

Este trabalho investigou a implementação categorial de modelos de regressão por meio da categoria Learn e da composição de learners. Os resultados obtidos indicam que a abordagem fornece uma descrição estrutural para diferentes etapas do aprendizado supervisionado, permitindo que transformações sejam combinadas sem alterar internamente os componentes já existentes.

Nos experimentos, a composição com um padronizador e a transformação quadrática permitiram representar funções mais complexas estritamente pela composição estrutural. A extensão para composição paralela amplia esse resultado ao permitir fluxos independentes de aprendizado.

A implementação mostra que listas heterogêneas tipadas constituem uma alternativa prática para representar o espaço de parâmetros de composições. A concatenação em nível de tipos permite que uma composição múltipla preserve explicitamente a origem de seus parâmetros. A principal contribuição do trabalho, portanto, não está apenas nos

valores numéricos obtidos pelos modelos, mas na demonstração de que diferentes capacidades podem ser acrescentadas por composição.

Como continuidade, pretende-se formalizar as propriedades algébricas da composição paralela, implementar polinômios mais complexos e estender a base para redes multicamadas com funções de ativação não-lineares, de modo a validar os aspectos estruturais em arquiteturas de maior complexidade.

8. FONTES CONSULTADAS

FONG, B.; SPIVAK, D. I.; TUYÊRAS, R. Backprop as functor: A compositional perspective on supervised learning. In: 2019 34th Annual ACM/IEEE Symposium on Logic in Computer Science (LICS). IEEE, 2019. p. 1–13.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep learning. MIT press, 2016.