

UMA GENERALIZAÇÃO ESTRUTURAL DO APRENDIZADO SUPERVISIONADO VIA TEORIA DAS CATEGORIAS

Kauã Santana da Silva

Alexandre Garcia de Oliveira

Fatec Baixada Santista – Rubens Lara

kaua.silva22@aluno.cps.sp.gov.br

OBJETIVOS

Algoritmos de aprendizado supervisionado podem ser estudados, sob a perspectiva da Teoria das Categorias (Mac Lane, 1998), como transformações entre espaços de dados que admitem composição. Este projeto de Iniciação Científica tem como objetivo investigar a aplicação da abordagem apresentada por Fong *et al.* (2019) no artigo *Backprop as functor*, que interpreta o backpropagation de Rumelhart *et al.* (1986) como funtor, para a representação estrutural do aprendizado supervisionado. A investigação busca compreender até que ponto essa estrutura pode ser estendida, tendo como etapas a implementação em categorias, sua generalização para multicategorias e, como trabalho futuro, sua extensão para PROPs.

MÉTODOS E PROCEDIMENTOS

A pesquisa é desenvolvida por meio do estudo da construção apresentada por Fong *et al.* (2019) e de sua implementação em Haskell. Na representação categorial, os algoritmos de aprendizado são modelados como morfismos entre espaços de dados, nomeados *learners*, permitindo sua composição para a construção de modelos mais complexos. A implementação utiliza recursos do sistema de tipos de Haskell, incluindo GADTs (Peyton Jones *et al.*, 2006) e *type families* (Chakravarty *et al.*, 2005), para representar espaços de parâmetros como listas heterogêneas ao nível de tipos, como feito por Kisselyov *et al.* (2004), permitindo que diferentes tipos de parâmetros sejam associados a um mesmo modelo.

A partir dessa estrutura, a pesquisa investiga a extensão da representação para múltiplas

entradas. Na generalização multicategorial (Leinster, 2004), um morfismo passa a representar uma transformação da forma $(A_1, \dots, A_n) \rightarrow B$.

A composição é, então, generalizada para a substituição de operações em diferentes entradas, de acordo com a estrutura de uma multicategoria. A utilização da mesma representação de listas heterogêneas para parâmetros e entradas introduz problemas relacionados à associação dos tipos. Como $((p, q), r)$ e $(p, (q, r))$ recebem representações distintas no sistema de tipos, utiliza-se `unsafeCoerce` para compatibilizá-las.

RESULTADOS

A investigação resultou na implementação de uma estrutura categorial para representar algoritmos de aprendizado supervisionado e na sua generalização para uma estrutura multicategorial. A extensão permite representar explicitamente múltiplas entradas, incorporando a aridade à assinatura dos morfismos, enquanto preserva o caso de entrada única como caso particular.

Como validação funcional da implementação, foi desenvolvido um modelo de regressão logística (Goodfellow *et al.*, 2016) com função de custo *Binary Cross-Entropy* (BCE), aplicado às classes *Iris setosa* e *Iris versicolor* do conjunto *Iris* (Fisher, 1936), caracterizando uma tarefa de classificação binária. O modelo iniciou com parâmetros nulos e,

após o treinamento, convergiu para [1,0877; -1,5202; 1,8492; 1,8661; 0,2012].

A implementação obteve acurácia de 100% no subconjunto utilizado, resultado compatível com a separabilidade linear das classes consideradas.

CONCLUSÕES

A pesquisa encontra-se em desenvolvimento e, até o presente estágio, indica que a abordagem categorial de Fong *et al.* fornece uma estrutura adequada para investigar composicionalmente algoritmos de aprendizado supervisionado. A generalização para multicategorias permite estender essa representação para modelos com múltiplas entradas, mantendo a composição como elemento estrutural do aprendizado.

Como continuidade da investigação, pretende-se estudar e implementar PROPs (Mac Lane, 1965), permitindo a representação de operações com múltiplas entradas e múltiplas saídas. Essa progressão permitirá avaliar qual nível de estrutura categorial é necessário para representar diferentes formas de composição em sistemas de aprendizado de máquina.

Os autores declaram não haver conflito de interesses.

Contribuições: Kauã Santana da Silva realizou a concepção e implementação, os experimentos, a análise dos resultados e a redação do trabalho. Alexandre Garcia de Oliveira realizou a orientação científica, discussão metodológica e revisão do manuscrito.

Bolsa acadêmica: O presente trabalho não recebeu bolsa acadêmica.

REFERÊNCIAS BIBLIOGRÁFICAS

Chakravarty, Manuel M. T.; Keller, Gabriele; Peyton Jones, Simon. Associated type synonyms. In: International Conference on Functional Programming. *Proceedings [...]*. Tallinn: ACM, 2005. p. 241-253.
Fisher, Ronald Aylmer. The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, v. 7, n. 2, p. 179-188, 1936.

Fong, Brendan; Spivak, David I.; Tuyéras, Rémy. Backprop as functor: a compositional perspective on supervised learning. In: *34th Annual ACM/IEEE Symposium on Logic in Computer Science (LICS)*. Vancouver: IEEE, 2019. p. 1-13.

Goodfellow, Ian; Bengio, Yoshua; Courville, Aaron. *Deep learning*. Cambridge: MIT Press, 2016.

Kisselyov, Oleg; Lämmel, Ralf; Schupke, Kean. Strongly typed heterogeneous collections. In: ACM SIGPLAN Haskell Workshop. *Proceedings [...]*. Snowbird: ACM, 2004. p. 41-60.

Leinster, Tom. *Higher operads, higher categories*. Cambridge: Cambridge University Press, 2004.

Mac Lane, Saunders. Categorical algebra. *Bulletin of the American Mathematical Society*, v. 71, n. 1, p. 40-106, 1965.

Mac Lane, Saunders. *Categories for the working mathematician*. 2. ed. New York: Springer, 1998.

Peyton Jones, Simon; Vytiniotis, Dimitrios; Weirich, Stephanie; Washburn, Geoffrey. Simple unification-based type inference for GADTs. In: Programming Language Design and Implementation. *Proceedings [...]*. Ottawa: ACM, 2006. p. 50-61.

Rumelhart, David E.; Hinton, Geoffrey E.; Williams, Ronald J. Learning representations by back-propagating errors. *Nature*, v. 323, p. 533-536, 1986.