Implementação Categorial de Modelos de Regressão via Composição de Morfismos

Kauã Santana da Silva
Prof. Dr. Alexandre Garcia de Oliveira

FATEC Baixada Santista Rubens Lara • Ciência de Dados • Santos/SP

I Simpósio de Ciência de Dados das Fatecs • Santos/SP • 2026

Sumário

1. Motivação

2. Categoria Learn, morfismos e composição

3. O funtor L

3. Implementação em Haskell

4. Modelos

5. Conclusões



I simpósio de CIÊNCIA DE DADOS das Fatecs

Fatec Baixada Santista Rubens Lara

Centro Paula Souza

SÃO PAULO GOVERNO DO ESTADO

Motivaçã
o

Visão procedural

- Propagar a entrada
- Calcular o erro
- Propagar o gradiente
- Atualizar os pesos

Descreve *como* o modelo aprende.

Visão estrutural

- Um *learner* é um morfismo
- Um modelo é um *learner* composto
- O *backpropagation* é descrito por um funtor

Descreve *o que é* o aprendizado.

Fong, Spivak, and Tuyéras 2019

I simpósio de CIÊNCIA DE DADOS das Fatecs

Fatec Baixada Santista Rubens Lara

Centro Paula Souza

SÃO PAULO GOVERNO DO ESTADO

Categoria Learn, morfismos e composição

Um morfismo $A \to B$ em $\mathbf{Learn}$ é dado por:

- $I : P \times A \to B$ predição (*implement*)
- $U : P \times A \times B \to P$ atualização (*update*)
- $r : P \times A \times B \to A$ requisição (*request*)

Composição $g \circ f$

$$I_{g \circ f} = I_g(q,\, I_f(p, a))$$
$$U_{g \circ f} = \big(U_f(p, a, r_g(\cdots)),\, U_g(\cdots)\big)$$
$$r_{g \circ f} = r_f(p,\, a,\, r_g(q, I_f(p, a), c))$$

$U_{g \circ f}$ codifica a atualização composta: f recebe a requisição produzida por g e, em seguida, g atualiza seus próprios parâmetros.

I simpósio de CIÊNCIA DE DADOS das Fatecs

Fatec Baixada Santista Rubens Lara

Centro Paula Souza

SÃO PAULO GOVERNO DO ESTADO

O funtor L

Dada uma predição $I : \mathbb{R}^k \times \mathbb{R}^m \to \mathbb{R}^n$, uma taxa de aprendizado ε e um erro e, no caso do erro quadrático,

$$U(p, a, y) = p - \varepsilon \nabla_p E_I(p, a, y) \qquad r(p, a, y) = a - \nabla_a E_I(p, a, y)$$

Regressão linear com $e = \frac{1}{2}(y - \hat{y})^2$

$$\frac{\partial e}{\partial w} = (wa + b - y) \cdot a$$
$$\frac{\partial e}{\partial b} = wa + b - y$$
$$\frac{\partial e}{\partial a} = (wa + b - y) \cdot w$$

Comunicação estrutural

As camadas exteriores recebem os sinais de erro das mais internas sem uma comunicação explícita entre elas. O erro é propagado estruturalmente via r.

I simpósio de CIÊNCIA DE DADOS das Fatecs
Fatec Baixada Santista Rubens Lara
Centro Paula Souza
SÃO PAULO GOVERNO DO ESTADO

Implementação em Haskell

Problema enfrentado

$$(p,(q,r)) \not\equiv ((p,q),r)$$

Solução: GADT + *type family*

```
data Params (ps :: [Type])
    where
  ParamsNull :: Params '[]
  (:::) :: p -> Params ps
        -> Params (p ': ps)

type family xs ++ ys where
  '[]       ++ ys = ys
  (x ': xs) ++ ys = x ': (xs
      ++ ys)
```

Uma composição $h \circ g \circ f$ é parametrizada por `[p, q, r]`, preservando os tipos de cada morfismo.

I simpósio de CIÊNCIA DE DADOS das Fatecs
Fatec Baixada Santista Rubens Lara
Centro Paula Souza
SÃO PAULO GOVERNO DO ESTADO

Implementação em Haskell

Typeclass Category

```
class Category cat where
  id  :: cat a a
  (.) :: cat b c -> cat a b -> cat a c
```

Typeclass Cat

```
class Cat (cat :: [Type] -> Type -> Type -> Type) where
  id  :: cat '[] a a
  (.) :: cat qs b c -> cat ps a b -> cat (ps ++ qs) a c
```

I simpósio de CIÊNCIA DE DADOS das Fatecs
Fatec Baixada Santista Rubens Lara
Centro Paula Souza
SÃO PAULO GOVERNO DO ESTADO

Modelos – Regressor Linear Simples

Morfismos

- $I(p, a) = wa + b,$
- $U(p, a, y) = \big(w - \varepsilon(wa + b - y)a,\ b - \varepsilon(wa + b - y)\big)$
- $r(p, a, y) = a - (wa + b - y) \cdot w$

Com $p = (w, b) \in \mathbb{R}^2$

Resultado

Dados de teste: $y = 2x + 1$ com ruído, $x \in \{1, \ldots, 16\}$

$\varepsilon = 0{,}006$ 1000 épocas

	Esperado	Obtido
w	2,000	2,012
b	1,000	0,697

Observação

Sem normalização, a superfície de perda é anisotrópica, tornando o modelo sensível ao ε.

I simpósio de CIÊNCIA DE DADOS das Fatecs

Fatec Baixada Santista Rubens Lara

Centro Paula Souza

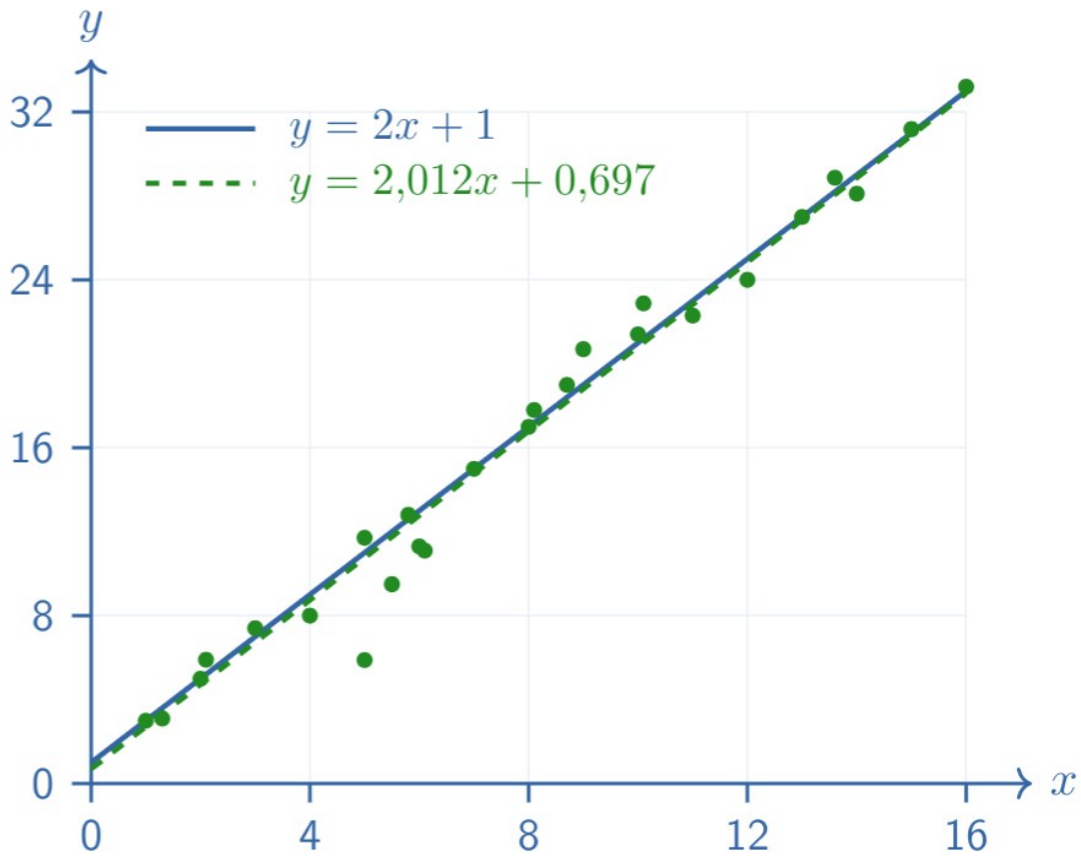
SÃO PAULO GOVERNO DO ESTADO

Modelos – Regressor Linear Simples

Reta considerada

$$f(x) = 2x + 1$$

- alvo: $2x + 1$
- ajuste: $2{,}012x + 0{,}697$
- $x \in \{1, \ldots, 16\}$, com ruído



I simpósio de CIÊNCIA DE DADOS das Fatecs

Fatec Baixada Santista Rubens Lara

Centro Paula Souza

SÃO PAULO GOVERNO DO ESTADO

Modelos – Regressor Linear Padronizado

Modelo como composição

$$\texttt{regressor} \circ \texttt{padronizador}$$

- $I(a) = \frac{(a-\mu)}{\sigma}$,
- $U(a, z) = []$
- $r(a, z) = a - \frac{1}{\sigma}\left(\frac{a-\mu}{\sigma} - z\right)$*

*$r(a, z)$ pela regra da cadeia:
$\nabla_a E_I = \left(\frac{a-\mu}{\sigma} - z\right)\frac{1}{\sigma}$

Resultado

Mesmos dados,
$\varepsilon = 0{,}01$, 1000 épocas

Predição para $x = 17$:

$$\hat{y} = 35{,}243 \quad \text{vs} \quad f(17) = 35$$

Erro: **0,7%**

Observação

A padronização pré-composta resolve sensibilidade do modelo ao ε, porém sem alterar o regressor.

I simpósio de CIÊNCIA DE DADOS das Fatecs

Fatec Baixada Santista
Rubens Lara

Centro Paula Souza

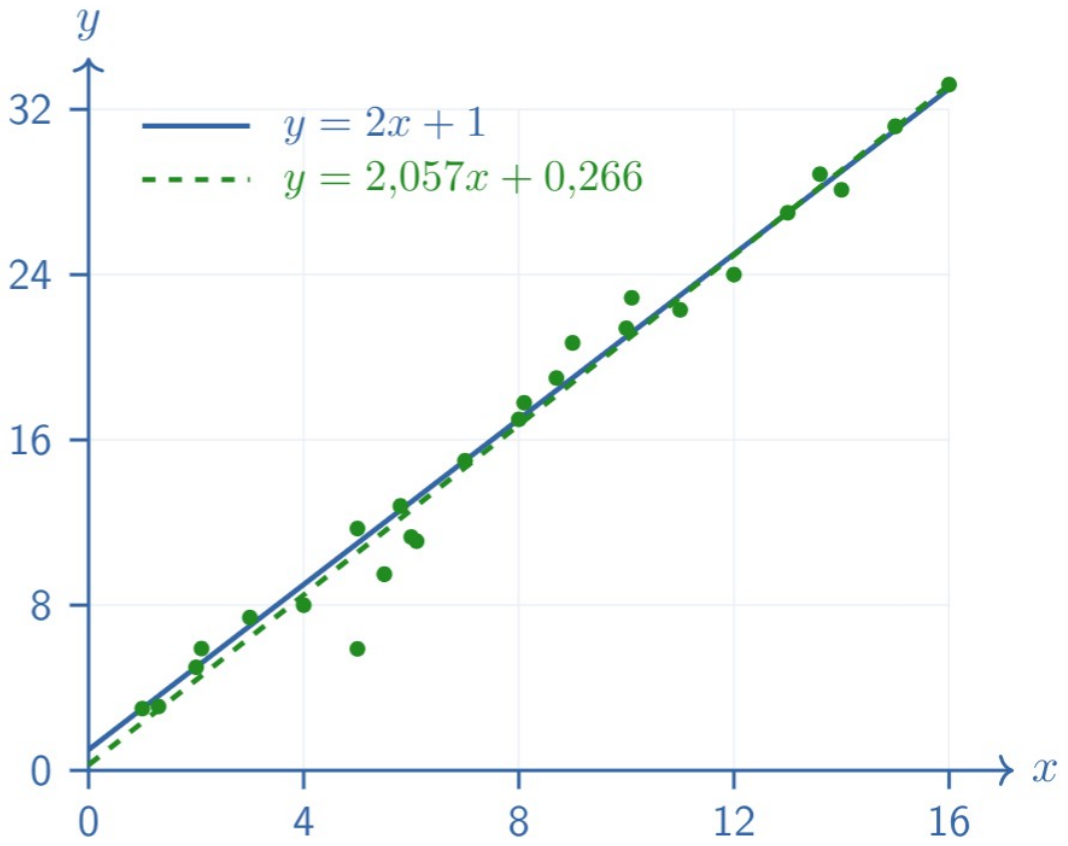
SÃO PAULO GOVERNO DO ESTADO

Modelos – Regressor Linear Padronizado

Reta considerada

$$f(x) = 2x + 1$$

- alvo: $2x + 1$
- ajuste: $2{,}057x + 0{,}266$
- $x \in \{1, \ldots, 16\}$, com ruído



I simpósio de CIÊNCIA DE DADOS das Fatecs

Fatec Baixada Santista Rubens Lara

Centro Paula Souza

SÃO PAULO GOVERNO DO ESTADO

Modelos – Regressor Polinomial

Composição tripla

$\texttt{regressor} \circ \texttt{padronizador} \circ \texttt{quadratico}$

$$a \xrightarrow{a^2} \xrightarrow{\frac{a^2-\mu}{\sigma}} \xrightarrow{w(\cdot)+b} \hat{y}$$

- $I(a) = a^2$,
- $U(a, z) = []$
- $r(a, z) = a - 2a(a^2 - z)$

Resultado

Dados de teste: $y = 0{,}3x^2 - 3$ com ruído,
$\varepsilon = 0{,}01$, 100 épocas

	Esperado	Obtido
w	0,300	0,296
b	$-3,000$	$-2,946$

Erros: **1,4%** e **1,8%**

Destaque

A não-linearidade merge da composição, sem alterar a estrutura.

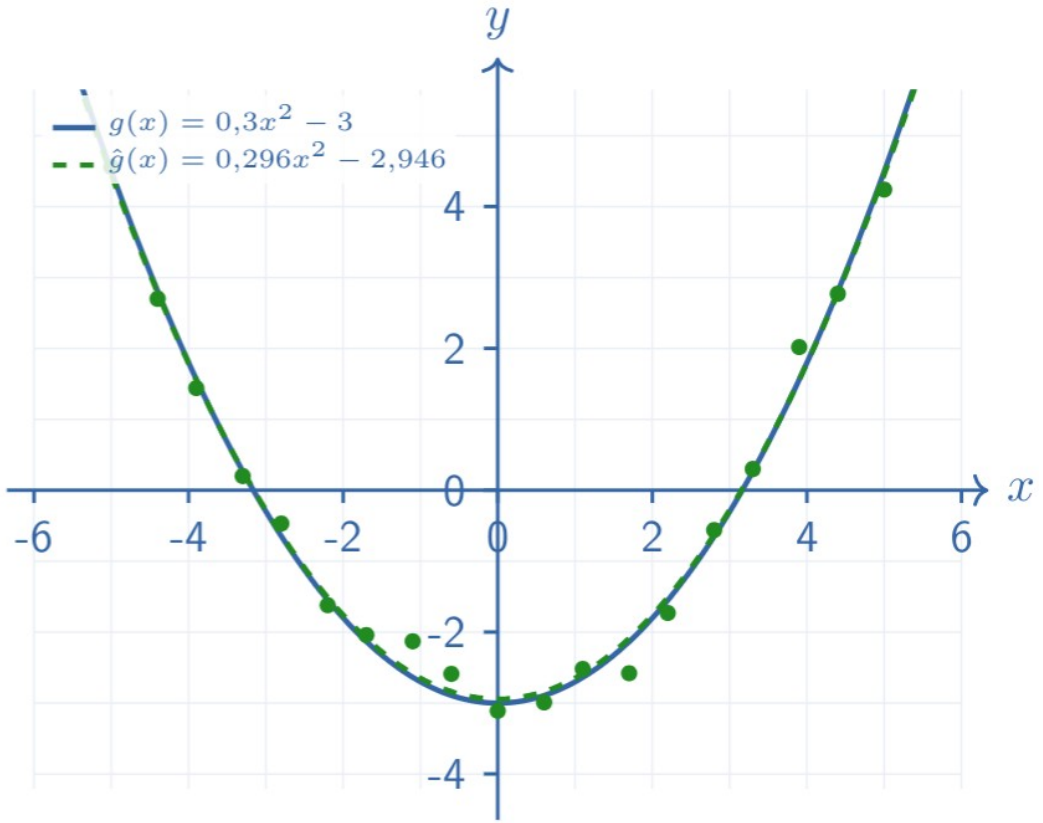
I simpósio de CIÊNCIA DE DADOS das Fatecs
Fatec Baixada Santista Rubens Lara
Centro Paula Souza
SÃO PAULO GOVERNO DO ESTADO

Modelos – Regressor Polinomial

Função considerada

$$g(x) = 0{,}3x^2 - 3$$

- coeficiente quadrático $0{,}3$
- intercepto -3
- crescimento não linear



I simpósio de CIÊNCIA DE DADOS das Fatecs

Fatec Baixada Santista Rubens Lara

Centro Paula Souza

SÃO PAULO GOVERNO DO ESTADO

Conclusões

Resultados parciais

- *Backpropagation* emerge da composição, sem implementação explícita
- Padronização resolve anisotropia sem modificar o regressor
- Não-linearidade emerge da composição com o *learner* quadrático

Trabalhos futuros

- Classificação: `regressor` ∘ `sigmoid`
- Rede multicamada com ativação não-linear
- Composição paralela monoidal

I simpósio de CIÊNCIA DE DADOS das Fatecs
Fatec Baixada Santista Rubens Lara
Centro Paula Souza
SÃO PAULO GOVERNO DO ESTADO

Referências

Fong, Brendan, David I. Spivak, and Rémy Tuyéras (2019). "Backprop as Functor: A Compositional Perspective on Supervised Learning". In: *Proceedings of the 34th Annual ACM/IEEE Symposium on Logic in Computer Science (LICS)*. IEEE, pp. 1–13. DOI: 10.1109/LICS.2019.8785665. URL: https://arxiv.org/abs/1711.10455.

I simpósio de CIÊNCIA DE DADOS das Fatecs

Fatec Baixada Santista Rubens Lara

Centro Paula Souza

SÃO PAULO GOVERNO DO ESTADO

SÃO PAULO
GOVERNO DO ESTADO

Centro Paula Souza

Fatec
Baixada Santista
Rubens Lara

I simpósio de
CIÊNCIA DE DADOS
das Fatecs

OBRIGADO(A)!

Perguntas e Discussão