


INTRODUÇÃO

O aprendizado supervisionado costuma ser descrito como uma sequência de operações: prever, calcular o erro, propagar o gradiente e atualizar os parâmetros. Essa leitura explica *como* o treinamento é executado, mas não explicita a estrutura que permite combinar modelos. Fong, Spivak e Tuyéras propõem a categoria **Learn** [1], na qual *learners* são morfismos e a retropropagação emerge de sua composição. Este trabalho implementa essa perspectiva em Haskell e investiga sua extensão para operações de múltiplas entradas. Assim, pergunta-se: como passar de cadeias de modelos $A \rightarrow B \rightarrow C$ para operações que combinem $(A_1, \dots, A_n)$ em uma única saída, preservando tipos, parâmetros e propagação do gradiente?

CATEGORIA LEARN

Na categoria **Learn** [1], um morfismo $A \rightarrow B$ é uma quádrupla (P, I, U, r) : P é o espaço de parâmetros, $I : P \times A \rightarrow B$ realiza a predição, $U : P \times A \times B \rightarrow P$ atualiza os parâmetros e $r : P \times A \times B \rightarrow A$ envia à camada anterior a informação necessária ao aprendizado. Na composição, o fluxo direto combina as implementações; o fluxo inverso combina atualização e requisição.




Na implementação, o produto cartesiano dos espaços de parâmetros foi substituído por uma lista heterogênea tipada, `Params ps`. Denota-se por $H(\vec{P})$ essa lista indexada pela sequência de tipos $\vec{P} = (P_1, \dots, P_m)$. A composição concatena essas sequências, preservando na assinatura a ordem e o tipo de cada componente. A mesma representação foi posteriormente aplicada às entradas de **MultiLearn**.

$$(P \times Q) \times R \not\equiv P \times (Q \times R) \implies H(P, Q, R)$$

Essa solução, porém, encontra uma limitação no sistema de tipos: como $(++)$ é uma família de tipos não injetiva, o GHC nem sempre consegue recuperar `ps` e `qs` ou demonstrar equivalências entre associações distintas. Como recurso paliativo, as projeções internas da estrutura empregam `unsafeCoerce`, transferindo para a implementação a responsabilidade de manter o índice do GADT coerente com seu conteúdo. Essa solução é sustentada pela Teoria das Categorias, que garante tal congruência, embora o GHC não consiga realizar as verificações necessárias.

MULTICATEGORIA MULTILEARN

Uma multicategoria substitui setas de entrada única por multimorfismos $f : (A_1, \dots, A_n) \rightarrow B$ [2]. A composição ocorre por substituição: em cada entrada de f é conectado um multimorfismo compatível [2, 3]. Para **MultiLearn**, a proposta é manter a quádrupla de aprendizado, mas representar as entradas por um vetor heterogêneo tipado; a requisição retorna uma informação de aprendizado para cada componente. Essa forma é adequada a modelos que combinam atributos ou ramos independentes [3].



Na implementação, um multimorfismo com entradas $\vec{A} = (A_1, \dots, A_n)$ mantém a quádrupla (P, I, U, r) de **Learn**. A mesma estrutura heterogênea H utilizada para os parâmetros passa a representar as entradas. Altera-se apenas a aridade da entrada e da requisição; quando $n = 1$, $H(A) = A$ e recupera-se exatamente **Learn**.

$$\begin{aligned} I &: H(\vec{P}) \times H(\vec{A}) \longrightarrow B, \\ U &: H(\vec{P}) \times H(\vec{A}) \times B \longrightarrow H(\vec{P}), \\ r &: H(\vec{P}) \times H(\vec{A}) \times B \longrightarrow H(\vec{A}). \end{aligned}$$

A Teoria das Categorias garante que toda categoria pode ser compreendida como uma multicategoria cujas operações são estritamente unárias [2]. Desse modo, **Learn** é preservada como o fragmento de aridade 1 de **MultiLearn**, mantendo suas identidades e sua composição enquanto a nova estrutura acrescenta operações genuinamente multiárias.

CONCLUSÕES E TRABALHOS FUTUROS

Tabela 1 – Resultados experimentais por estrutura

Estrutura	Modelo	Composição ou arquitetura	Resultado principal
Learn	Linear	<i>learner</i> isolado	Para a reta $f(x) = 2x + 1$ e 1000 épocas, apresentou um erro aproximado de 0.53%; sensível à escala.
Learn	Padronizado	<i>linear</i> ◦ padronizador	Para a reta $f(x) = 2x + 1$ e 1000 épocas, apresentou um erro aproximado de 0.69%; mais estável.
Learn	Polinomial	<i>linear</i> ◦ padronizador ◦ quadrático	Para o polinômio $f(x) = 0,3x^2 - 3$ e 200 épocas, apresentou um erro aproximado de 4.10%.
Learn	Logístico	<i>sigmoid</i> ◦ <i>linear</i> ◦ padronizador	Para a função logística $f(x) = \frac{1}{1+e^{-\frac{w(x-p)}{\sigma+b}}}$ e 1000 épocas, apresentou um erro aproximado de 0.003%.
Learn	<i>small-net</i>	BCE ◦ densa ◦ ReLU ◦ densa ◦ z-score	Acurácia de 100,0% no Iris binário com duas componentes (100 épocas).
MultiLearn	<i>iris-multi</i>	<i>linear</i> ◦ BCE	Acurácia de 100,0% no Iris [5] binário (100 épocas).
MultiLearn	<i>bank-multi</i>	MLP: $4 \rightarrow 16 \rightarrow 1$	Acurácia de 98,01% no Banknote [6] (100 épocas).

Fonte: Elaborado pelo autor (2026), com base nos conjuntos de dados de Fisher (1936) [5] e Lohweg (2012) [6].

A contribuição central é estrutural: modelos mais expressivos surgem da composição de unidades simples, e a retropropagação decorre da composição em **Learn**. **MultiLearn** substitui cadeias por operações com várias entradas, preservando a aridade 1 e permitindo estudar arquiteturas pela topologia das conexões. Os experimentos confirmam a execução composicional de I , U e r , mas não provam, isoladamente, os axiomas categoriais.

No entanto, a tradução da matemática para o sistema de tipos exige controlar concatenação, associação e decomposição de listas heterogêneas. Ainda é necessário substituir coerções não verificadas por evidências explícitas de tipos e testar as leis multiárias. Como continuidade, propõe-se uma **PROP colorida**, capaz de representar processos $m \rightarrow n$ com múltiplas entradas e saídas, composição sequencial e paralela [4].

REFERÊNCIAS

- [1] FONG, B.; SPIVAK, D. I.; TUYÉRAS, R. *Backprop as functor: a compositional perspective on supervised learning*. In: **ACM/IEEE SYMPOSIUM ON LOGIC IN COMPUTER SCIENCE**, 34., 2019. *Proceedings* [...]. [S. l.]: IEEE, 2019. p. 1–13. DOI: 10.1109/LICS.2019.8785665.
- [2] LEINSTER, T. *Higher operads, higher categories*. Cambridge: Cambridge University Press, 2004. cap. 2, p. 34.
- [3] SPIVAK, D. I. *The operad of wiring diagrams: formalizing a graphical language for databases, recursion, and plug-and-play circuits*. *arXiv preprint*, arXiv:1305.0297, 2013.

- [4] LACK, S. *Composing PROPs. Theory and Applications of Categories*, v. 13, n. 9, p. 147–163, 2004.
- [5] FISHER, R. A. *Iris* [conjunto de dados]. UCI Machine Learning Repository, 1936. DOI: 10.24432/C56C76.
- [6] LOHWEG, V. *Banknote Authentication* [conjunto de dados]. UCI Machine Learning Repository, 2012. DOI: 10.24432/C55P57.